

Лекция: Введение в анализ данных

# Exploratory Data Analysis

лектор Артём Лебедев



# Введение

**Exploratory Data Analysis (EDA)** — это процесс исследования данных с целью выявления их структуры, закономерностей, аномалий и взаимосвязей. EDA помогает понять данные, сформулировать гипотезы и подготовить данные для дальнейшего анализа или моделирования.

## **Основные этапы EDA:**

1. Сбор данных
2. Очистка данных
3. Исследование данных
4. Предобработка данных
5. Формулирование гипотез


# Визуализация данных

**Гистограммы:** используются для визуализации распределения числовых данных. Позволяют оценить форму распределения (нормальное, скошенное, бимодальное и т.д.), выявить выбросы и необычные пики.




# Визуализация данных

**Scatter plots (диаграммы рассеяния):** отображают взаимосвязь между двумя числовыми переменными. Полезны для выявления корреляций (линейных и нелинейных), кластеризации данных и обнаружения выбросов.



# Визуализация данных


**Box plots (ящики с усами):** компактно отображают медиану, квартили и выбросы в данных. Помогают оценить разброс, асимметрию распределения и сравнить несколько распределений на одном графике.



# Визуализация данных

## Measures of Central Tendency, Mean, Median & Mode


Mean, Median, Mode






Mode

Median

Mean



# Визуализация данных



# Использование Pandas для работы с табличными данными

**Pandas** — это мощная библиотека Python для работы с табличными данными и анализа данных.

Основные структуры данных:

- DataFrame
- Series

## Series

|   | apples |
|---|--------|
| 0 | 3      |
| 1 | 2      |
| 2 | 0      |
| 3 | 1      |

+

## Series

|   | oranges |
|---|---------|
| 0 | 0       |
| 1 | 3       |
| 2 | 7       |
| 3 | 2       |

=

## DataFrame

|   | apples | oranges |
|---|--------|---------|
| 0 | 3      | 0       |
| 1 | 2      | 3       |
| 2 | 0      | 7       |
| 3 | 1      | 2       |

# Использование Pandas для работы с табличными данными

## Основные операции:

- Загрузка данных
- Просмотр данных
- Фильтрация данных
- Группировка данных
- Агрегация данных
- **Обработка пропусков**
- Объединение данных



# Обработка пропусков, выбросов

**Пропуски данных** — это отсутствующие значения в данных.

Способы обработки:


- Удаление строк с пропусками: `dropna()` (удаляет строки с любым количеством пропусков) или `dropna(subset=['column1', 'column2'], how='any')` (удаляет строки, где есть пропуски хотя бы в одном из указанных столбцов).
- Заполнение пропусков: (например, средним, медианой `df['column'].median()`, модой `df['column'].mode()[0]` или конкретным значением `df['column'].fillna(0)`)
- Более сложные методы заполнения: интерполяция, предсказание на основе других переменных и т.д.

# Обработка пропусков, выбросов

**Выбросы** — это аномальные значения, которые значительно отличаются от остальных данных.

Способы обработки:

- Визуальный анализ с помощью box plot, scatter plot, гистограмм.
- Удаление выбросов на основе статистических критериев, например, межквартильный размах (IQR)
- Замена выбросов на граничные значения
- Использование робастных методов, устойчивых к выбросам (например, робастное масштабирование).



# Масштабирование данных

**Масштабирование данных** — это процесс приведения числовых признаков к единому масштабу, что важно для многих алгоритмов машинного обучения, особенно для тех, которые чувствительны к масштабу признаков.

**StandardScaler:** стандартизация данных (вычитание среднего и деление на стандартное отклонение). После этого признак имеет среднее 0 и стандартное отклонение 1. Полезно для данных с нормальным распределением.

**MinMaxScaler:** нормализация данных в диапазон  $[0, 1]$  или  $[-1, 1]$ . Каждое значение вычитается из минимума и делится на размах (разницу между максимумом и минимумом). Полезно для данных с произвольным распределением.

# Масштабирование данных




**StandardScaler**

$$X(\text{scaled}) = (X_i - X_{\text{mean}}) / \text{StDev}$$

**MinMaxScaler**

$$X(\text{scaled}) = (X_i - X_{\text{min}}) / (X_{\text{max}} - X_{\text{min}})$$


# Масштабирование данных



# Кодирование категориальных признаков

**Категориальные признаки** — это переменные, которые принимают ограниченное количество значений (например, пол, цвет, страна). Для работы с ними в моделях машинного обучения их нужно преобразовать в числовой формат.

- **One-Hot Encoding:** создание бинарных столбцов для каждого значения категории. Каждая категория кодируется как отдельный бинарный признак. Позволяет сохранить категориальную информацию, но может создавать много новых признаков.
- **Label Encoding:** присвоение каждой категории уникального числа. Простой способ, но может ввести нежелательный порядок между категориями.
- **Target Encoding:** каждая категория кодируется средним значением целевой переменной для этой категории. Более сложный способ, но может улучшить производительность моделей.



**Спасибо за  
внимание и до  
скорых встреч!**