



Машинное обучение

Лекция 7: Линейная регрессия

Докладчик: Тима Бовт



Что рассмотрим сегодня?

- Постановка задачи линейной регрессии
- Метод наименьших квадратов
- Теорема Гаусса-Маркова
- Мультиколлинеарность
- Регуляризация
- Нелинейные преобразования признаков и различные функции потерь
- Градиентный спуск

Постановка задачи линейной регрессии



Постановка задачи

Пусть задана выборка $\mathbb{D} = (X|y)_{i=1}^n$, где $X \subseteq \mathbb{X} = \mathbb{R}^{n \times m}$, $y \subseteq \mathbb{Y} = \mathbb{R}^n$, то есть

$$\mathbb{D} = \begin{pmatrix} x_{11} & \dots & x_{1m} & y_1 \\ \vdots & \ddots & \vdots & \vdots \\ x_{n1} & \dots & x_{nm} & y_n \end{pmatrix}.$$

Необходимо найти такое отображение $f : \mathbb{X} \rightarrow \mathbb{Y}$, которое лучше всего приближает истинное соответствие между множеством пространством $\mathbb{X}$ и пространством ответов $\mathbb{Y}$.



Постановка задачи

Это задача регрессии, для решения которой мы будем использовать семейство линейных моделей с параметром $w = (w_0, \dots, w_m) \in \mathbb{W} = \mathbb{R}^m$.

$$f(x, w) = w_0 + \sum_{j=1}^m w_j x_j, \quad x_j \in \mathbb{R}^n.$$

Если ввести фиктивную переменную $x_0 = (1, \dots, 1)^T \in \mathbb{R}^n$, то модель линейной регрессии можно обозначить

$$f(x, w) = (w, x) = Xw, \quad x \in \mathbb{R}^n.$$


Таким образом, задача линейной регрессии состоит в том, чтобы найти такие значения параметров w_j , чтобы построенное линейное отображение лучше всего приближало истинную зависимость между $\mathbb{X}$ и $\mathbb{Y}$.



Постановка задачи

Регрессия

Прогнозирование числового значения



Метод наименьших квадратов



Условия модели

Если мы введем случайную величину $\varepsilon \in \mathbb{R}^n$ – шум, то математическая модель рассматриваемого эксперимента задается формулой

$$y = Xw + \varepsilon,$$

при условии, что

- ошибки не носят систематического характера, то есть $\mathbb{E}(\varepsilon_i | x_i) = 0 \ \forall i$;
- дисперсия ошибок одинакова и равна $\mathbb{D}(\varepsilon_i) = \sigma^2 \ \forall i$ (гомоскедастичность);
- ошибки некоррелированы, то есть $cov(\varepsilon_i, \varepsilon_j) = 0 \ \forall i \neq j$.

Наша задача заключается в том, чтобы найти значения неизвестного вектора параметров w . Для этого нам нужно построить наилучшую оценку $\hat{w}$, которая максимально приблизит нас к истинному значению w . Задача оценивания параметров является задачей математической статистики. Для ее решения воспользуемся методом максимального правдоподобия.



Функция правдоподобия

В рамках введенных условий на математическую модель, мы считаем, что случайные ошибки ε берутся из центрированного нормального распределения

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2), \quad i = \overline{1, n}.$$

Тогда распределение целевой переменной

$$y_i | X, w \sim \mathcal{N}(x_i^T w, \sigma^2).$$

Отсюда функция правдоподобия

$$L(X, w) = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \cdot e^{-\frac{\sum_{i=1}^n (y_i - x_i^T w)^2}{2\sigma^2}}.$$



Функция правдоподобия

Для получения оценки максимального правдоподобия решается задача оптимизации

$$L(X, w) = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \cdot e^{-\frac{\sum_{i=1}^n (y_i - x_i^T w)^2}{2\sigma^2}} \rightarrow \max_w.$$

Из метода максимального правдоподобия известно, что можно взять логарифм функции правдоподобия для решения этой задачи оптимизации:

$$\ln L(X, w) = -n \ln(\sigma\sqrt{2\pi}) - \frac{\sum_{i=1}^n (y_i - x_i^T w)^2}{2\sigma^2} \rightarrow \max_w.$$

Упростим эту задачу и, умножив на -1, приведем к задаче минимизации:

$$\sum_{i=1}^n (y_i - x_i^T w)^2 \rightarrow \min_w.$$



Mean Squared Error

Определим в рассматриваемом пространстве $\mathbb{R}^n$ нормы

$$\|x\|_1 = \sum_{i=1}^n |x_i|, \quad \|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}.$$

Решая задачу отыскания оценки максимального правдоподобия, мы пришли в задаче оптимизации функционала

$$L(X, y, w) = \sum_{i=1}^n (y_i - x_i^T w)^2 = \|y - Xw\|_2^2.$$

Такой функционал ошибки не очень хорош для сравнения поведения моделей на выборках разного размера. Гораздо лучше нормировать его

$$MSE(X, y, w) = \frac{1}{n} \sum_{i=1}^n (y_i - x_i^T w)^2 = \frac{1}{n} \|y - Xw\|_2^2.$$

Полученная функция называется **Mean Squared Error, MSE** или **среднеквадратическим отклонением**.



Задача оптимизации

Таким образом, для получения оценки максимального правдоподобия $\hat{w}$ необходимо решить задачу минимизации среднеквадратичного отклонения:

$$MSE(X, y, w) = \frac{1}{n} \sum_{i=1}^n (y_i - x_i^T w)^2 \rightarrow \min_w.$$



Оценка параметра

Воспользуемся одним из простейших способов отыскания минимума: через производную целевой функции. Для этого запишем MSE в матричной форме:

$$MSE(X, y, w) = \frac{1}{n}(y - Xw)^T(y - Xw).$$

Возьмем производную по искомому параметру:

$$\frac{\partial MSE(X, y, w)}{\partial w} = \frac{1}{n} \frac{\partial}{\partial w} (y^T y - y^T Xw - w^T X^T y + w^T X^T Xw) = -\frac{2}{n} X^T (y - Xw)$$

и нам необходимо найти w , при котором она обращается в ноль:

$$-\frac{2}{n} X^T (y - Xw) = 0.$$

Тогда оценка параметра равна

$$\hat{w} = (X^T X)^{-1} X^T y.$$

Теорема Гаусса-Маркова



Теорема Гаусса-Маркова

- ошибки не носят систематического характера, то есть $\mathbb{E}(\varepsilon_i|x_i) = 0 \ \forall i$;
- дисперсия ошибок одинакова и равна $\mathbb{D}(\varepsilon_i) = \sigma^2 \ \forall i$ (гомоскедастичность);
- ошибки некоррелированы, то есть $cov(\varepsilon_i, \varepsilon_j) = 0 \ \forall i \neq j$.

Теорема Гаусса-Маркова гласит, что, имея в виду все определения и условия на ε описанные выше, оценки метода наименьших квадратов оптимальны в классе линейных несмещённых оценок. То есть, говоря простыми словами, в каком-то смысле мы получили наилучшую оценку для параметра w . Она и используется для получения аналитического решения.

Мультиколлинеарность



Мультиколлинеарность

Если среди признаков, то есть столбцов матрицы X , есть линейно зависимые, то определитель матрицы $X^T X$ равен нулю и её обращение $(X^T X)^{-1}$ невозможно. Следовательно, аналитического решения нет. Однако такой вариант маловероятен. Чаще происходит следующее. Если матрица имеет полный ранг, но столбцы почти линейно зависимы (сильная корреляция), то говорят что матрица плохо обусловлена. Почти линейную зависимость среди признаков называют *проблемой мультиколлинеарности*. Она ведет к

- *большому разбросу* по абсолютной величине и знаку у коэффициентов $\hat{w}$;
- значение $\|\hat{w}\|$ будет велико;
- *неустойчивому обучению*, то есть добавление или удаление нескольких объектов из матрицы X влечет значительно разные оптимальные $\hat{w}$;
- *неустойчивому решению*, то есть малое изменение входных данных влечет сильное изменение значения функции регрессии;
- как следствие, возникает переобучение.

Таким образом, задача может оказаться некорректно поставленной.



Мультиколлинеарность

Для борьбы с мультиколлинеарностью можно прибегнуть к следующим вариантам

- удалять скоррелированные столбы;
- вводить ограничения на параметры;
- произвести преобразование признаков (создать новые признаки на основе старых);
- добавить штраф в функционале качества, зависящий от значений параметров (регуляризация).



Обращение матрицы

Однако обращение матрицы $X^T X$ влечет еще одну проблему. Основная проблема в обращении матрицы – это то, что вычислительно обращать большие матрицы дело сложное, а мы бы хотели работать с датасетами, в которых у нас могут быть миллионы точек. Однако можно избежать вычисления обратной матрицы. Один из способов – использование псевдообратной матрицы, которая в свою очередь предполагает сингулярное разложение матрицы. Таким образом, можно сделать предварительное QR-разложение или SVD-разложение матрицы, что упростит операцию обращения.

Регуляризация



Ridge

Метод гребневой регрессии (Ridge regression) состоит в добавлении слагаемого, штрафующего за большие веса (за увеличение $\|\hat{w}\|_{L_2}$)

$$\mathcal{L}_\lambda(X, y, w) = \|y - Xw\|^2 + \lambda\|w\|^2$$

компоненту $\lambda\|w\|^2$ называют **квадратичным регуляризатором**, а параметр $\lambda > 0$ – **параметром регуляризации**.

В этом случае аналитическое решение может быть построено как

$$\frac{\partial \mathcal{L}_\lambda(X, y, w)}{\partial w} = -2X^T(y - Xw) + 2\lambda w = 0,$$

$$\hat{w}_\lambda = (X^T X + \lambda E_n)^{-1} X^T y,$$

где E_n – единичная матрица размера $n \times n$.



Гиперпараметр

Коэффициент λ является гиперпараметром модели, он достаточно сильно влияет на качество итогового решения. Его подбирают по логарифмической шкале (приблизительно от 10^{-3} до 10^2), используя для сравнения моделей с разными значениями λ дополнительную валидационную выборку (например, подход кросс-валидации). При этом качество модели с подобранным коэффициентом регуляризации уже проверяют на тестовой выборке, чтобы исключить переобучение.



LASSO

Другая идея состоит в добавлении ограничения на сумму абсолютных значений весов, называемая методом **LASSO** (Least Absolute Shrinkage and Selection Operator):

$$\begin{cases} \mathcal{L}(X, y, w) = \|y - Xw\|^2 \rightarrow \min_w \\ \sum_{j=0}^n |w_j| \leq t, \end{cases}$$

где параметр t иногда называют селективностью. Используя метод множителей Лагранжа, можно записать в виде

$$\mathcal{L}_\lambda(X, y, w) = \|y - Xw\|^2 + \lambda \|w\|_1 \rightarrow \min_w,$$


где взаимосвязь между t и λ зависит от данных.

Особенность метода LASSO состоит в умении отбирать признаки. С уменьшением параметра λ мы можем обнулять некоторые веса. Это дает возможность автоматически избавляться от признаков, которые участвуют в соотношениях приближенной линейной зависимости, соответственно, спасает от проблем, связанных с мультиколлинеарностью.




Ridge и LASSO

L_2 -регуляризация



L_1 -регуляризация





Elastic Net

Иногда может быть полезна комбинация из L_1 и L_2 регуляризаций, называемая **Elastic Net**:

$$\mathcal{L}_\lambda(X, y, w) = \|y - Xw\|^2 + \lambda\|w\|_1 + (1 - \lambda)\|w\|_2 \rightarrow \min_w .$$

Нелинейные признаки и различные функции потерь



Нелинейные преобразования

От исходного признакового пространства $X \subset \mathbb{R}^{n \times m}$ можно перейти к новым признакам с помощью преобразования $X \xrightarrow{g} X' \subset \mathbb{R}^{n \times k}$.

К примеру, если нам необходимо построить более сложную нелинейную по признакам модель

$$f(x, w) = w_1 x_1 + w_2 \ln x_2 + w_3 x_1^2 + w_4 \sin x_1 x_2,$$

то можно перейти к новому преобразованному пространству признаков с помощью преобразования

$$g(x) = (x_1, \ln x_2, x_1^2, \sin x_1 x_2),$$

тогда мы приходим к линейной модели

$$f(x', w) = w_1 x'_1 + w_2 x'_2 + w_3 x'_3 + w_4 x'_4.$$


Также можно строить нелинейные относительно параметров w модели $f(x, w)$, например

$$f(x, w) = \cos(x_1 w_1) + \sin(x_2 w_2)$$




Пример нелинейной модели

Линейная



Нелинейная





Различные функции потерь

Ранее было оговорено, что можно выбирать для минимизации эмпирического риска различные функции потерь, необязательно останавливаясь на MSE. Также иногда применяются

- $MAE(X, y, w) = \frac{1}{n} \sum_{i=1}^n |y_i - x_i^T w|$ – Mean Absolute Error;
- $MAPE(X, y, w) = \frac{1}{n} \sum_{i=1}^n |y_i - x_i^T w|$ – Mean Absolute Percentage Error;
- $RMSE(X, y, w) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - x_i^T w)^2}$ – Root Mean Squared Error;

Градиентный спуск



Численные методы

Из курса численных методов известно, что для задач, в которых отыскание аналитического точного решения вызывает трудности, мы можем воспользоваться итерационными методами для отыскания приближенного решения. Одним из таких численных методов является градиентный спуск. Также из курса методов оптимизации, учитывая тот факт, что функционал MSE, который нам необходимо минимизировать, является гладким и выпуклым, следует, что использование градиентных методов действительно поможет нам эффективно найти точку его локального (глобального) минимума.

Вообще говоря, используя градиентные методы, мы можем отыскивать решение не только в случае базовой линейной регрессии с функцией потерь MSE, но и в случае нелинейной регрессии или не квадратичной функции потерь.



Градиентный спуск

$$L(f, X, y) = \sum_{i=1}^n \mathcal{L}(f(x_i, w), y_i) \rightarrow \min_w$$

Вектор частных производных (градиент) по параметрам в общем виде:

$$\frac{\partial L}{\partial w_j} = \sum_{i=1}^n \frac{\partial \mathcal{L}}{\partial f} \cdot \frac{\partial f}{\partial w_j}.$$

Градиент функции в точке направлен в сторону её наискорейшего роста, а антиградиент (противоположный градиенту вектор) в сторону наискорейшего убывания. То есть имея какое-то приближение оптимального значения параметра $w^{(k)}$, мы можем его улучшить, посчитав градиент функции потерь в точке и немного сдвинув вектор весов в направлении антиградиента:

$$w_j^{(k+1)} = w_j^{(k)} - \alpha \frac{\partial L}{\partial w_j^{(k)}},$$

где параметр $\alpha > 0$ называют темпом обучения (learning rate).



Градиентный спуск

Градиент для MSE в качестве функции потерь мы уже считали

$$\frac{\partial MSE(X, y, w)}{\partial w} = \frac{2}{n} X^T (Xw - y).$$

Тогда в случае MSE итерационный процесс градиентного спуска для корректировки весов линейной регрессии задается формулой

$$w^{(k+1)} = w^{(k)} - \alpha \cdot \frac{2}{n} X^T (Xw^{(k)} - y).$$

- Поскольку задача выпуклая, выбор начальной точки влияет на скорость сходимости, но не настолько сильно, чтобы на практике нельзя было стартовать всегда из нуля или из любой другой приятной вам точки;
- Темп обучения α тоже сильно влияет на поведение градиентного спуска; вообще говоря, он является гиперпараметром алгоритма, и его приходится подбирать отдельно. Другими гиперпараметрами являются максимальное число итераций и/или порог tolerance.



SGD

Обозначим за K максимальное число итераций градиентного спуска. Тогда вычислительная сложность этого алгоритма — $O(K \cdot n \cdot t)$, где сложность вычисления градиента $O(nt)$. При больших значениях t и n процесс вычисления становится достаточно долгим. Но если количество признаков t мы не можем изменить, то остается пытаться изменять количество объектов n . Отсюда возникает новый метод — стохастический градиентный спуск (stochastic gradient descent, SGD).

Идея SGD состоит в том, чтобы вычислять не точное значение градиента по всей выборке X , а оценить по некоторой подвыборке $X' \subset X$, размерности $B \ll n$ (то есть небольшого размера). Такая подвыборка называется **батчем**.

$$\frac{\partial L}{\partial w} \approx \frac{1}{B} \sum_{i=1}^B \frac{\partial L(f, x_i, y_i)}{\partial w}.$$

Методы градиентного спуска требуют предварительной нормализации выборки.



Батчи

Как делить выборку на батчи? Ясно, что можно было бы случайным образом сэмплировать их из полного датасета, но даже если использовать быстрый алгоритм вроде резервуарного сэмплирования, сложность этой операции не самая оптимальная. Поэтому используют линейный проход по выборке (которую перед этим лучше всё-таки случайным образом перемешать). Давайте введём ещё один параметр нашего алгоритма: размер батча, который мы обозначим B . Теперь на B очередных примерах вычислим градиент и обновим веса модели. При этом вместо количества шагов алгоритма обычно задают количество эпох E . Это ещё один гиперпараметр. Одна эпоха – это один полный проход нашего сэмплера по выборке. Заметим, что если выборка очень большая, а модель компактная, то даже первый проход бывает можно не заканчивать.



SGD и GD

Разница между алгоритмами может быть изображена так



<https://education.yandex.ru/handbook/ml/article/linear-models>

Шаги стохастического градиентного спуска заметно более шумные, но считать их получается значительно быстрее. В итоге они тоже сходятся к оптимальному значению. По крайней мере, сходимость можно получить при хорошо подобранных коэффициентах темпа обучения в случае выпуклого функционала качества. Для сложных моделей и лоссов стохастический градиентный спуск может сходиться плохо или застревать в локальных минимумах, поэтому придумано множество его улучшений.



Что сегодня рассмотрели?

- Формула линейной регрессии
- Оценка параметров линейной регрессии
- Как бороться с мультиколлинеарностью
- Ridge, LASSO, Elastic Net регуляризации
- Эмпирический риск, функция потерь
- Нелинейные модели регрессии
- GD и SGD методы