

Введение в RecSys

Кирилл Ляхнович
RecSys R&D Lead @ T-Bank

Минск, 24 марта 2025

План

Пройдемся по основным темам

1. Зачем нужны рекомендательные системы
2. Постановка задачи
3. Метрики и анализ
4. Основные подходы
5. Важные нюансы рекомендательных систем

Что можно рекомендовать?

Краткий ответ - все, что угодно

- ✦ Товары на маркетплейсах (WB, Ozon, 21vek и тд.)
- ✦ Фильмы (Netflix, VOCA)
- ✦ Музыку (Spotify, Я.Музыка)
- ✦ Контент в соцсетях (посты, истории, короткие видео)
- ✦
- ✦ Вопросы, которые нужно задать во время идентификации
- ✦ Время, в которое нужно отправить клиенту пуш-уведомление
- ✦ Категории повышенных кэшбэков

Зачем нужны рекомендации?

Польза для пользователей

- ✦ Релевантные предложения, удовлетворяющие потребности, интересы и ожидания
- ✦ Снижение негатива (от лишних коммуникаций, нерелевантных предложений)
- ✦ Экономия времени и сил на поиск
- ✦ Повышенный exploration

Зачем нужны рекомендации?

Польза для бизнеса

- ✦ Увеличение продуктовых и бизнес-метрик (конверсии в просмотры, клики, покупки)
- ✦ Дополнительная монетизация (прирост к доходу или экономии)
- ✦ Вовлеченность пользователей (e.g. MAU, retention, timespent)
- ✦ Лояльность пользователей (e.g. NPS)
- ✦ Улучшение клиентского опыта (e.g. CSAT)

Постановка задачи - Глоссарий

Постановка задачи - Глоссарий

- **User** (пользователь)- тот, кто будет пользоваться рекомендациями

Постановка задачи - Глоссарий

- **User** (пользователь)- тот, кто будет пользоваться рекомендациями
- **Item** - объект, который мы рекомендуем. В конкретных кейсах обычно заменяется более узким термином, например пост, товар, и т.д.

Постановка задачи - Глоссарий

- **User** (пользователь)- тот, кто будет пользоваться рекомендациями
- **Item** - объект, который мы рекомендуем. В конкретных кейсах обычно заменяется более узким термином, например пост, товар, и т.д.
- **Interaction** (взаимодействие) - событие, при котором **user** совершил какое-то действие с **item**-ом. Интеракции делятся на 2 типа по **feedback**:
 - **Explicit** interaction - **user** явно поставил свою оценку для **item**. Например, оценил ресторан в Яндекс Картах.
 - **Implicit** interaction - **user** провзаимодействовал с **item**, но мы точно не знаем насколько ему понравилось. Например оставил комментарий.

Постановка задачи

Постановка задачи

Interaction Matrix (Матрица взаимодействий) - ключевой объект в рекомендательных системах, который содержит в себе информацию о том, с какими **item**'ами взаимодействовали **user**'ы

Постановка задачи

Interaction Matrix (Матрица взаимодействий) - ключевой объект в рекомендательных системах, который содержит в себе информацию о том, с какими **item**'ами взаимодействовали **user**'ы

	User 1	User 2	User 3
Item 1	0	?	0
Item 2	1	0	1
Item 3	1	?	?
Item 4	?	1	1

Матрица лайков reels

Постановка задачи

Interaction Matrix (Матрица взаимодействий) - ключевой объект в рекомендательных системах, который содержит в себе информацию о том, с какими **item**'ами взаимодействовали **user**'ы

	User 1	User 2	User 3
Item 1	0	?	0
Item 2	1	0	1
Item 3	1	?	?
Item 4	?	1	1

Матрица лайков reels

	User 1	User 2	User 3
Item 1	?	3	1
Item 2	?	2	?
Item 3	0	0	1
Item 4	1	?	4

Матрица маркетплейса

- 0 - просмотр
- 1 - клик
- 2 - в избранное
- 3 - в корзину
- 4 - заказ

Постановка задачи

Постановка задачи

Задачи рекомендательной системы:

1. Правильно аппроксимировать пропуск, проставив некоторый **score** (оценка релевантности или вероятности, выданная системой)

Постановка задачи

Задачи рекомендательной системы:

1. Правильно аппроксимировать пропуск, проставив некоторый **score** (оценка релевантности или вероятности, выданная системой)



Постановка задачи

Задачи рекомендательной системы:

1. Правильно аппроксимировать пропуск, проставив некоторый **score** (оценка релевантности или вероятности, выданная системой)



2. Из полученных скоров сформировать выдачу рекомендованных айтемов с учетом бизнес-правил, юридических требований и требований к **diversity**



Постановка задачи

Задачи рекомендательной системы:

1. Правильно аппроксимировать пропуск, проставив некоторый **score** (оценка релевантности или вероятности, выданная системой)




2. Из полученных скоров сформировать выдачу рекомендованных айтемов с учетом бизнес-правил, юридических требований и требований к **diversity**

0.867	0.866	0.865	0.85	0.849	0.843	0.842
						


Постановка задачи

Задачи рекомендательной системы:

1. Правильно аппроксимировать пропуск, проставив некоторый **score** (оценка релевантности или вероятности, выданная системой)



2. Из полученных скоров сформировать выдачу рекомендованных айтемов с учетом бизнес-правил, юридических требований и требований к **diversity**



Метрики

Для оценки часто используются @k метрики:

Метрики

Для оценки часто используются @k метрики:

$$\text{Precision @ } k = \frac{1}{n} \sum \frac{\text{сколько релевантных в топ-}k}{k}$$

Метрики

Для оценки часто используются @k метрики:

$$\text{Precision @ } k = \frac{1}{n} \sum \frac{\text{сколько релевантных в топ-}k}{k}$$


Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C

Метрики

Для оценки часто используются @k метрики:

$$\text{Precision @ } k = \frac{1}{n} \sum \frac{\text{сколько релевантных в топ-}k}{k}$$

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C



Метрики

Для оценки часто используются @k метрики:

$$\text{Precision @ } k = \frac{1}{n} \sum \frac{\text{сколько релевантных в топ-}k}{k}$$

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C




Precision@5 =

Метрики

Для оценки часто используются @k метрики:

$$\text{Precision @ } k = \frac{1}{n} \sum \frac{\text{сколько релевантных в топ-}k}{k}$$

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C



Precision@5 =


$$\frac{1}{3} \left(\frac{3}{5} + \frac{1}{5} + \frac{4}{5} \right) \approx 0.53$$

Метрики

Для оценки часто используются @k метрики:

$$\text{Precision@}k = \frac{1}{n} \sum \frac{\text{сколько релевантных в топ-}k}{k}$$

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C



Precision@3 =

Precision@5 =


$$\frac{1}{3} \left(\frac{3}{5} + \frac{1}{5} + \frac{4}{5} \right) \approx 0.53$$

Метрики

Для оценки часто используются @k метрики:

$$\text{Precision@}k = \frac{1}{n} \sum \frac{\text{сколько релевантных в топ-}k}{k}$$

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C



Precision@3 =

$$\frac{1}{3} \left(\frac{1}{3} + 0 + \frac{2}{3} \right) \approx 0.33$$

Precision@5 =

$$\frac{1}{3} \left(\frac{3}{5} + \frac{1}{5} + \frac{4}{5} \right) \approx 0.53$$

Метрики

Для оценки часто используются @k метрики:

Метрики

Для оценки часто используются @k метрики:

Hit Rate @ k = $\frac{1}{n} \sum$ есть хотя бы 1 релевантный среди топ- k

Метрики

Для оценки часто используются @k метрики:

Hit Rate @ $k = \frac{1}{n} \sum$ есть хотя бы 1 релевантный среди топ- k


Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C

Метрики

Для оценки часто используются @k метрики:

Hit Rate @ $k = \frac{1}{n} \sum$ есть хотя бы 1 релевантный среди топ- k

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C



Метрики

Для оценки часто используются @k метрики:

Hit Rate @ $k = \frac{1}{n} \sum$ есть хотя бы 1 релевантный среди топ- k

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C



HitRate@5 =

Метрики

Для оценки часто используются @k метрики:

Hit Rate @ $k = \frac{1}{n} \sum$ есть хотя бы 1 релевантный среди топ- k

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C



$$\text{HitRate@5} = \frac{1}{3}(1 + 1 + 1) = 1$$

Метрики

Для оценки часто используются @k метрики:

Hit Rate @ $k = \frac{1}{n} \sum$ есть хотя бы 1 релевантный среди топ- k

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C

$$\text{HitRate@5} = \frac{1}{3}(1 + 1 + 1) = 1$$

Метрики

Для оценки часто используются @k метрики:

Hit Rate @ $k = \frac{1}{n} \sum$ есть хотя бы 1 релевантный среди топ- k

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C



HitRate@3 =




HitRate@5 = $\frac{1}{3}(1 + 1 + 1) = 1$

Метрики

Для оценки часто используются @k метрики:

Hit Rate @ $k = \frac{1}{n} \sum$ есть хотя бы 1 релевантный среди топ- k

Rank	User 1 recommendations	User 2 recommendations	User 3 recommendations
1	A	F	J
2	B	E	E
3	C	C	K
4	D	A	D
5	E	B	C


$$\text{HitRate@3} = \frac{1}{3}(1 + 0 + 1) \approx 0.67$$

$$\text{HitRate@5} = \frac{1}{3}(1 + 1 + 1) = 1$$

Метрики - Average Precision @k:

Метрики - Average Precision @k:

Rank	Item	Precision@K	Rank	Item	Precision@K
1		1/1	1		0/1
2		2/2	2		0/2
3		2/3	3		0/3
4		2/4	4		0/4
5		2/5	5		1/5
6		2/6	6		2/6

 Relevant item  Irrelevant item

Метрики - Average Precision @k:

Rank	Item	Precision@K	Rank	Item	Precision@K	$rel(k) = [k\text{-ый item релевантен}]$
1		1/1	1		0/1	
2		2/2	2		0/2	
3		2/3	3		0/3	
4		2/4	4		0/4	
5		2/5	5		1/5	
6		2/6	6		2/6	

 Relevant item  Irrelevant item

Метрики - Average Precision @k:

Rank	Item	Precision@K	Rank	Item	Precision@K
1		1/1	1		0/1
2		2/2	2		0/2
3		2/3	3		0/3
4		2/4	4		0/4
5		2/5	5		1/5
6		2/6	6		2/6

 Relevant item  Irrelevant item

$rel(k) = [k\text{-ый item релевантен}]$

$$AP @ k = \frac{1}{\sum_{i=1}^k rel(i)} \sum_{i=1}^k rel(i) \cdot Precision@i$$

Метрики - Average Precision @k:

Rank	Item	Precision@K	Rank	Item	Precision@K
1		1/1	1		0/1
2		2/2	2		0/2
3		2/3	3		0/3
4		2/4	4		0/4
5		2/5	5		1/5
6		2/6	6		2/6

 Relevant item  Irrelevant item

$rel(k) = [k\text{-ый item релевантен}]$

$$AP @ k = \frac{1}{\sum_{i=1}^k rel(i)} \sum_{i=1}^k rel(i) \cdot Precision@i$$

Это метрика **ранжирования**,
т.к. учитывает порядок рекомендаций

Метрики - Average Precision @k:

Rank	Item	Precision@K	Rank	Item	Precision@K
1		1/1	1		0/1
2		2/2	2		0/2
3		2/3	3		0/3
4		2/4	4		0/4
5		2/5	5		1/5
6		2/6	6		2/6

 Relevant item  Irrelevant item

$rel(k) = [k\text{-ый item релевантен}]$

$$AP @ k = \frac{1}{\sum_{i=1}^k rel(i)} \sum_{i=1}^k rel(i) \cdot Precision@i$$

Это метрика **ранжирования**,
т.к. учитывает порядок рекомендаций

1-ый список:

$$AP @ 6 = \frac{1}{2} \left(\frac{1}{1} + \frac{2}{2} + 0 + 0 + 0 + 0 \right) = 1$$

Метрики - Average Precision @k:

Rank	Item	Precision@K	Rank	Item	Precision@K
1		1/1	1		0/1
2		2/2	2		0/2
3		2/3	3		0/3
4		2/4	4		0/4
5		2/5	5		1/5
6		2/6	6		2/6

 Relevant item  Irrelevant item

$rel(k) = [k\text{-ый item релевантен}]$

$$AP @ k = \frac{1}{\sum_{i=1}^k rel(i)} \sum_{i=1}^k rel(i) \cdot Precision@i$$

Это метрика **ранжирования**,
т.к. учитывает порядок рекомендаций

1-ый список:

$$AP @ 6 = \frac{1}{2} \left(\frac{1}{1} + \frac{2}{2} + 0 + 0 + 0 + 0 \right) = 1$$

2-ой список:

$$AP @ 6 = \frac{1}{2} \left(0 + 0 + 0 + 0 + \frac{1}{5} + \frac{2}{6} \right) \approx 0.265$$


Метрики - Mean Average Precision @k:

MAP@k Позволяет усреднить AP@k по M пользователям


$$\text{MAP@K} = \frac{1}{M} \sum_{j=1}^M \frac{1}{r} \sum_{k=1}^K \text{Precision@k} \cdot \text{rel}(k)$$

Normalized Discounted Cumulative Gain

Normalized Discounted Cumulative Gain




Normalized Discounted Cumulative Gain



$$CG@k = \sum_{i=1}^k \text{rel}(i)$$


Normalized Discounted Cumulative Gain



$$CG@k = \sum_{i=1}^k \text{rel}(i)$$

$$CG@6 = 0 + 0 + 1 + 0 + 1 + 1 = 3$$

Normalized Discounted Cumulative Gain




$$CG@k = \sum_{i=1}^k \text{rel}(i)$$

$$DCG@k = \sum_{i=1}^k \frac{\text{rel}(i)}{\log_2(1 + i)}$$

$$CG@6 = 0 + 0 + 1 + 0 + 1 + 1 = 3$$


Normalized Discounted Cumulative Gain

 $CG@k = \sum_{i=1}^k \text{rel}(i)$ $DCG@k = \sum_{i=1}^k \frac{\text{rel}(i)}{\log_2(1+i)}$

$$CG@6 = 0 + 0 + 1 + 0 + 1 + 1 = 3$$

$$DCG@6 = \frac{0}{\log_2 2} + \frac{0}{\log_2 3} + \frac{1}{\log_2 4} + \frac{0}{\log_2 5} + \frac{1}{\log_2 6} + \frac{1}{\log_2 7} \approx 1.24$$

Normalized Discounted Cumulative Gain



$$CG@k = \sum_{i=1}^k \text{rel}(i)$$


$$DCG@k = \sum_{i=1}^k \frac{\text{rel}(i)}{\log_2(1 + i)}$$

$$CG@6 = 0 + 0 + 1 + 0 + 1 + 1 = 3$$

$$NDCG@k = \frac{DCG@k}{\text{Ideal } DCG@k}$$

$$DCG@6 = \frac{0}{\log_2 2} + \frac{0}{\log_2 3} + \frac{1}{\log_2 4} + \frac{0}{\log_2 5} + \frac{1}{\log_2 6} + \frac{1}{\log_2 7} \approx 1.24$$

Normalized Discounted Cumulative Gain



$$CG@k = \sum_{i=1}^k \text{rel}(i) \quad DCG@k = \sum_{i=1}^k \frac{\text{rel}(i)}{\log_2(1+i)}$$


$$NDCG@k = \frac{DCG@k}{\text{Ideal } DCG@k}$$

$$CG@6 = 0 + 0 + 1 + 0 + 1 + 1 = 3$$

$$DCG@6 = \frac{0}{\log_2 2} + \frac{0}{\log_2 3} + \frac{1}{\log_2 4} + \frac{0}{\log_2 5} + \frac{1}{\log_2 6} + \frac{1}{\log_2 7} \approx 1.24$$

$$\text{Ideal } DCG@6 = \frac{1}{\log_2 2} + \frac{1}{\log_2 3} + \frac{1}{\log_2 4} + \frac{0}{\log_2 5} + \frac{0}{\log_2 6} + \frac{0}{\log_2 7} \approx 2.13$$

Normalized Discounted Cumulative Gain



$$CG@k = \sum_{i=1}^k \text{rel}(i) \qquad DCG@k = \sum_{i=1}^k \frac{\text{rel}(i)}{\log_2(1+i)}$$

$$CG@6 = 0 + 0 + 1 + 0 + 1 + 1 = 3$$
$$NDCG@k = \frac{DCG@k}{\text{Ideal } DCG@k}$$

$$DCG@6 = \frac{0}{\log_2 2} + \frac{0}{\log_2 3} + \frac{1}{\log_2 4} + \frac{0}{\log_2 5} + \frac{1}{\log_2 6} + \frac{1}{\log_2 7} \approx 1.24$$

$$\text{Ideal } DCG@6 = \frac{1}{\log_2 2} + \frac{1}{\log_2 3} + \frac{1}{\log_2 4} + \frac{0}{\log_2 5} + \frac{0}{\log_2 6} + \frac{0}{\log_2 7} \approx 2.13$$

$$NDCG@6 = \frac{1.24}{2.13} \approx 0.58$$

Подходы к построению рекомендаций

Подходы к построению рекомендаций

Top Popular - очень сильный baseline

Подходы к построению рекомендаций

Top Popular - очень сильный baseline

Идея: $\text{scores} := \text{частоты взаимодействия с айтемами}$

Подходы к построению рекомендаций

Top Popular - очень сильный baseline

Идея: $\text{scores} :=$ частоты взаимодействия с айтемами

Плюсы: простой, не требует сложных вычислений, используется как эталон

Подходы к построению рекомендаций

Top Popular - очень сильный baseline

Идея: $\text{scores} :=$ частоты взаимодействия с айтемами

Плюсы: простой, не требует сложных вычислений, используется как эталон

Минусы: отсутствие персонализации, отсутствие exploration, низкий coverage

Подходы к построению рекомендаций

Top Popular - очень сильный baseline

Идея: $\text{scores} := \text{частоты взаимодействия с айтемами}$

Плюсы: простой, не требует сложных вычислений, используется как эталон

Минусы: отсутствие персонализации, отсутствие exploration, низкий coverage

Top Personal - часто еще сильнее top-popular

Подходы к построению рекомендаций

Top Popular - очень сильный baseline

Идея: $\text{scores} :=$ частоты взаимодействия с айтемами

Плюсы: простой, не требует сложных вычислений, используется как эталон

Минусы: отсутствие персонализации, отсутствие exploration, низкий coverage

Top Personal - часто еще сильнее top-popular

Идея: $\text{scores} :=$ частоты взаимодействия с айтемами (для каждого юзера свои)

Подходы к построению рекомендаций

Top Popular - очень сильный baseline

Идея: $\text{scores} :=$ частоты взаимодействия с айтемами

Плюсы: простой, не требует сложных вычислений, используется как эталон

Минусы: отсутствие персонализации, отсутствие exploration, низкий coverage

Top Personal - часто еще сильнее top-popular

Идея: $\text{scores} :=$ частоты взаимодействия с айтемами (для каждого юзера свои)

Плюсы: хороший baseline с персонализацией

Подходы к построению рекомендаций

Top Popular - очень сильный baseline

Идея: $\text{scores} :=$ частоты взаимодействия с айтемами

Плюсы: простой, не требует сложных вычислений, используется как эталон

Минусы: отсутствие персонализации, отсутствие exploration, низкий coverage

Top Personal - часто еще сильнее top-popular

Идея: $\text{scores} :=$ частоты взаимодействия с айтемами (для каждого юзера свои)

Плюсы: хороший baseline с персонализацией

Минусы: холодный старт, требует специфическую задачу, closed feedback loop

Подходы: User-Based Collaborative Filtering

Подходы: User-Based Collaborative Filtering

Идея: Давайте посмотрим, какую оценку айтому ставили похожие пользователи

Подходы: User-Based Collaborative Filtering

Идея: Давайте посмотрим, какую оценку айтему ставили похожие пользователи

	Звездные войны	Дюна	Гарри Поттер	Властелин Колец
Вася			?	
Петя				
Настя				
Катя				

Подходы: User-Based Collaborative Filtering

Идея: Давайте посмотрим, какую оценку айтому ставили похожие пользователи

	Звездные войны	Дюна	Гарри Поттер	Властелин Колец
Вася			?	
Петя				
Настя				
Катя				

Активность Васи очень похожа на активность Насти, поэтому раз Насте понравился Гарри Поттер, то и Васе скорее всего понравится

Подходы: User-Based Collaborative Filtering

Перепишем более формально

r_{vj} — оценка, которую пользователь v поставил айтому j , $r_{vj} \in \{-1, 0, 1\}$

Подходы: User-Based Collaborative Filtering

Перепишем более формально

r_{vj} – оценка, которую пользователь v поставил айтому j , $r_{vj} \in \{-1, 0, 1\}$

$Sim(u, v)$ – Функция "сходства" пользователей u и v

Подходы: User-Based Collaborative Filtering

Перепишем более формально

r_{vj} – оценка, которую пользователь v поставил айтому j , $r_{vj} \in \{-1, 0, 1\}$

$Sim(u, v)$ – Функция "сходства" пользователей u и v

Например: $Sim(u, v) = \sum_{j \in I} r_{uj} r_{vj} = u^T v$

Подходы: User-Based Collaborative Filtering

Перепишем более формально

r_{vj} – оценка, которую пользователь v поставил айтому j , $r_{vj} \in \{-1, 0, 1\}$

$Sim(u, v)$ – Функция "сходства" пользователей u и v

Например: $Sim(u, v) = \sum_{j \in I} r_{uj} r_{vj} = u^T v$

Тогда можем **оценить** релевантность айтема i юзеру u как оценку других пользователей, взвешенную по похожести:

Подходы: User-Based Collaborative Filtering

Перепишем более формально

r_{vj} – оценка, которую пользователь v поставил айтому j , $r_{vj} \in \{-1, 0, 1\}$

$Sim(u, v)$ – Функция "сходства" пользователей u и v

Например: $Sim(u, v) = \sum_{j \in I} r_{uj} r_{vj} = u^T v$

Тогда можем **оценить** релевантность айтема i юзеру u как оценку других пользователей, взвешенную по похожести:

$$\hat{r}_{ui} = \frac{\sum_{v \in U \setminus u} Sim(u, v) \cdot r_{vi}}{\sum_{v \in U \setminus u} Sim(u, v)}$$

Подходы: Item-Based Collaborative Filtering

Идея: Похожие юзеры выбирают похожие айтемы

Подходы: Item-Based Collaborative Filtering

Идея: Похожие юзеры выбирают похожие айтемы

$Sim(i, j)$ – Функция "сходства" айтемов i и j

Подходы: Item-Based Collaborative Filtering

Идея: Похожие юзеры выбирают похожие айтемы

$Sim(i, j)$ – Функция "сходства" айтемов i и j

Например: $Sim(i, j) = \sum_{u \in U} r_{ui} r_{uj} = i^T j$

Подходы: Item-Based Collaborative Filtering

Идея: Похожие юзеры выбирают похожие айтемы

$Sim(i, j)$ – Функция "сходства" айтемов i и j

Например: $Sim(i, j) = \sum_{u \in U} r_{ui} r_{uj} = i^T j$

Как применить: Если юзер посмотрел фильм **A**, то ему скорее всего понравятся и фильмы, при которых **Sim(A, _)** максимальна.

Подходы: Matrix Factorization (Still CF)



10	-1	8	10	9	4
8	9	10	-1	-1	8
10	5	4	9	-1	-1
9	10	-1	-1	-1	3
6	-1	-1	-1	8	10

User-item Interaction Matrix
(R)

$\approx$

User Matrix
(Q)

$\times$

Item Matrix
(P)

Подходы: Matrix Factorization

$$\hat{R} \approx Q^T P$$

Подходы: Matrix Factorization

$$\hat{R} \approx Q^T P$$

Оптимизация функционала: $||R - Q^T P||_F \rightarrow \min_{Q,P}$

Подходы: Matrix Factorization

$$\hat{R} \approx Q^T P$$

Оптимизация функционала: $||R - Q^T P||_F \rightarrow \min_{Q,P}$

После этого получаем:

Подходы: Matrix Factorization

$$\hat{R} \approx Q^T P$$

Оптимизация функционала: $||R - Q^T P||_F \rightarrow \min_{Q,P}$

После этого получаем:

q_i — векторное представление i -го юзера

p_j — векторное представление j -го айтема

Подходы: Matrix Factorization

$$\hat{R} \approx Q^T P$$

Оптимизация функционала: $||R - Q^T P||_F \rightarrow \min_{Q,P}$

После этого получаем:

q_i – векторное представление i -го юзера

p_j – векторное представление j -го айтема

Теперь получить оценку
релевантности очень просто: $\hat{r}_{ij} = q_i^T p_j$

Подходы: Matrix Factorization

Оптимизация функционала: $||R - Q^T P||_F \rightarrow \min_{Q,P}$

Подходы: Matrix Factorization

Оптимизация функционала: $||R - Q^T P||_F \rightarrow \min_{Q,P}$

Существуют очень много подходов к матричной факторизации, самые популярные это:

Подходы: Matrix Factorization

Оптимизация функционала: $||R - Q^T P||_F \rightarrow \min_{Q,P}$

Существуют очень много подходов к матричной факторизации, самые популярные это:

1) **SVD** - классический алгоритм матричной факторизации, работает хорошо, но для маленьких датасетов

Подходы: Matrix Factorization

Оптимизация функционала: $||R - Q^T P||_F \rightarrow \min_{Q,P}$

Существуют очень много подходов к матричной факторизации, самые популярные это:

- 1) **SVD** - классический алгоритм матричной факторизации, работает хорошо, но для маленьких датасетов
- 2) **Alternating Least Squares (ALS)** - эффективный алгоритм, при котором поочередно оптимизируется то матрица Q, то матрица P. Хорошо работает на огромных датасетах + очень гибкий. Оптимизация происходит градиентными методами.

Свойства CF методов

- ✦ Самодостаточные методы, опираются только на историю взаимодействий
- ✦ Существуют эффективные реализации алгоритмов
- ✦ Хорошо объясняются пользователю
- ✦ Проблема холодного старта
- ✦ Не учитывают контент
- ✦ Не учитывают порядок рекомендаций

Content-Based Рекомендации

e_i — вектор-эмбеддинг айтема i из некоторого внешнего эмбеддера

Content-Based Рекомендации

e_i – вектор-эмбеддинг айтема i из некоторого внешнего эмбеддера

$Sim(i, j)$ – Функция "сходства" контента айтемов i и j

Content-Based Рекомендации

e_i – вектор-эмбеддинг айтема i из некоторого внешнего эмбеддера

$Sim(i, j)$ – Функция "сходства" контента айтемов i и j

Например, косинусная близость контентных эмбеддингов: $Sim(i, j) = \frac{e_i^T e_j}{\|e_i\| \|e_j\|}$

Content-Based Рекомендации

e_i – вектор-эмбеддинг айтема i из некоторого внешнего эмбеддера

$Sim(i, j)$ – Функция "сходства" контента айтемов i и j

Например, косинусная близость контентных эмбеддингов: $Sim(i, j) = \frac{e_i^T e_j}{\|e_i\| \|e_j\|}$

Как применить: Если юзер лайкнул пост **A**, то ему скорее всего понравятся и другие посты похожие по смыслу на **A**, т.е. при которых **Sim(A, _)** максимальна.

Свойства Content-Based методов

- ✦ Без проблем обрабатывают холодных пользователей
- ✦ Позволяют учитывать информацию о рекомендуемом контенте
- ✦ Хорошо объясняются пользователю
- ✦ Не учитывают историю взаимодействия
- ✦ Не учитывают порядок рекомендаций
- ✦ Полагаются на внешние модели

Ранжирующие методы

Учитывают порядок айтемов в оптимизационной задаче

Ранжирующие методы

Учитывают порядок айтемов в оптимизационной задаче

Один из самых популярных методов:

BPR - Bayesian Personalized Ranking (Относится к классу MF)

Ранжирующие методы

Учитывают порядок айтемов в оптимизационной задаче

Один из самых популярных методов:

BPR - Bayesian Personalized Ranking (Относится к классу MF)

Идея в том, что мы будем предсказывать вот такую штуку:

Ранжирующие методы

Учитывают порядок айтемов в оптимизационной задаче

Один из самых популярных методов:

BPR - Bayesian Personalized Ranking (Относится к классу MF)

Идея в том, что мы будем предсказывать вот такую штуку:

$\hat{r}_{uij} = P(\text{пользователь } u \text{ даст айтему } i \text{ лучшую оценку, чем айтему } j)$

Ранжирующие методы

Ранжирующие методы

$\hat{r}_{uij} = P(\text{пользователь } u \text{ даст айтому } i \text{ лучшую оценку, чем айтому } j)$

Ранжирующие методы

$\hat{r}_{uij} = P(\text{пользователь } u \text{ даст айтому } i \text{ лучшую оценку, чем айтому } j)$

$$\hat{r}_{uij} = P(\hat{r}_{ui} - \hat{r}_{uj} > 0) = \sigma(\hat{r}_{ui} - \hat{r}_{uj}) = \sigma(q_u^T p_i - q_u^T p_j)$$

Ранжирующие методы

$\hat{r}_{uij} = P(\text{пользователь } u \text{ даст айтому } i \text{ лучшую оценку, чем айтому } j)$

$$\hat{r}_{uij} = P(\hat{r}_{ui} - \hat{r}_{uj} > 0) = \sigma(\hat{r}_{ui} - \hat{r}_{uj}) = \sigma(q_u^T p_i - q_u^T p_j)$$

Оптимизируем вот такой функционал:

Ранжирующие методы

$\hat{r}_{uij} = P(\text{пользователь } u \text{ даст айтому } i \text{ лучшую оценку, чем айтому } j)$

$$\hat{r}_{uij} = P(\hat{r}_{ui} - \hat{r}_{uj} > 0) = \sigma(\hat{r}_{ui} - \hat{r}_{uj}) = \sigma(q_u^T p_i - q_u^T p_j)$$

Оптимизируем вот такой функционал:

$$\sum_{(u,i,j) \in D, r_{ui} > r_{uj}} -\log \sigma(q_u^T p_i - q_u^T p_j) \rightarrow \min_{Q,P}$$

Свойства Ранжирующих методов

- ✦ Сохраняют преимущества CF, метрики обычно выше
- ✦ Позволяют учесть порядок в оптимизационной задаче
- ✦ Есть эффективные алгоритмы
- ✦ Требуют более сложной предобработки данных
- ✦ Без модификаций не учитывают контент и имеют проблему холодного старта

Feedback loop

Философские проблемы рекомендательных систем

Feedback loop

Философские проблемы рекомендательных систем

- Рекомендательная система со временем учится на данных, которые сама же порекомендовала в прошлом. Из-за этого мы можем “застрять” в некотором информационном пузыре.

Feedback loop

Философские проблемы рекомендательных систем

- Рекомендательная система со временем учится на данных, которые сама же порекомендовала в прошлом. Из-за этого мы можем “застрять” в некотором информационном пузыре.
- Есть риск, что рекомендательная система подстроится под множество самых популярных пользователей или товаров

Feedback loop

Философские проблемы рекомендательных систем

- Рекомендательная система со временем учится на данных, которые сама же порекомендовала в прошлом. Из-за этого мы можем “застрять” в некотором информационном пузыре.
- Есть риск, что рекомендательная система подстроится под множество самых популярных пользователей или товаров
- ◆ Решение: повышать diversity, делать меньшую зависимость от коллаборативного сигнала, мониторить метрики “здоровья”

Дополнительные метрики измерения качества

Diversity (разнообразие) - число рекомендаций из разных категорий, степень различия рекомендаций между сессиями пользователя, различие рекомендаций между пользователями.

Novelty (новизна) - сколько среди рекомендаций новых для пользователей объектов.

Coverage (покрытие) - доля объектов, которые хотя бы раз побывали среди топа рекомендаций.


Serendipity (догадливость) - способность угадывать неожиданные нетривиальные предпочтения пользователя.

Важные нюансы рекомендательных систем

Единственный доступный способ проверить эффект от внедрения изменений в рекомендательную систему - **A/B тест**

Важные нюансы рекомендательных систем

Единственный доступный способ проверить эффект от внедрения изменений в рекомендательную систему - **A/B тест**



Важные нюансы рекомендательных систем

Свежесть рекомендаций

Важные нюансы рекомендательных систем

Свежесть рекомендаций

- ✦ **Offline (Батчевые)** рекомендации - обновляются заранее (например, за день)

Важные нюансы рекомендательных систем

Свежесть рекомендаций

- ✦ **Offline (Батчевые)** рекомендации - обновляются заранее (например, за день)
- ✦ **Near-RealTime** рекомендации - обновляются почти в реальном времени

Важные нюансы рекомендательных систем

Свежесть рекомендаций

- ✦ **Offline (Батчевые)** рекомендации - обновляются заранее (например, за день)
- ✦ **Near-RealTime** рекомендации - обновляются почти в реальном времени
- ✦ **RealTime (Online)** рекомендации - рекомендации обновляются на лету

Спасибо за внимание!

1. https://t.me/ods_recommender_systems
2. https://t.me/recsys_for_all
3. https://t.me/knowledge_accumulator
4. <https://t.me/inforetriever>
5. <https://t.me/ml4value>
6. <https://t.me/researchoshnaya>
7. <https://t.me/WazowskiRecommends>
8. <https://t.me/wildrecsys>
9. <https://t.me/mlvok>
10. <https://t.me/RecSysChannel>

